

Adaptação de modelos de linguagem de grande porte para automação de processos administrativos públicos: um sistema de recuperação aumentada por geração aplicado à Universidade Federal de Ouro Preto

Tchairô Niddan Ruiz Gimenez Leão

Universidade Federal de Ouro Preto (UFOP), Ouro Preto - MG, Brasil

Thiago Fontes Santos

Universidade Federal de Ouro Preto (UFOP), Ouro Preto - MG, Brasil

RESUMO

Este trabalho relata o desenvolvimento de um sistema de inteligência artificial para apoiar a automação de processos administrativos da Universidade Federal de Ouro Preto, a partir da adaptação de um modelo de linguagem de código aberto. O objetivo geral do projeto foi construir uma base de conhecimento vetorial a partir de documentos oficiais da instituição e integrá-la a um modelo de linguagem capaz de responder perguntas sobre resoluções, editais e normas internas. Os procedimentos metodológicos envolveram a coleta automatizada de documentos publicados pelo setor de órgãos colegiados da universidade, a extração e a segmentação de seu conteúdo textual, a criação de uma base vetorial de busca semântica e o ajuste fino supervisionado de um modelo de linguagem por meio de uma técnica de adaptação de baixo posto em precisão reduzida. Os resultados indicam que a recuperação semântica sobre um acervo superior a dez mil segmentos de texto produziu respostas tecnicamente consistentes quando combinada a um modelo de instrução de maior porte, ao passo que o ajuste fino aplicado a uma variante menor do modelo não foi suficiente, isoladamente, para eliminar respostas incoerentes com os documentos de origem. Identificaram-se também restrições relevantes de hardware para a implantação local da solução, superadas por meio de estratégias de quantização e de particionamento de camadas entre memória de vídeo e memória do sistema. Conclui-se que a combinação entre recuperação de informação e modelos de linguagem de código aberto constitui alternativa viável e replicável para a automação de tarefas administrativas em instituições públicas com recursos computacionais limitados.

Palavras-chave: Modelos de linguagem. Recuperação de informação. Administração pública. Inteligência artificial.

*Adapting large language models for public administrative process automation:
a retrieval-augmented generation system applied to the Federal University of
Ouro Preto*

ABSTRACT

This paper reports the development of an artificial intelligence system to support the automation of administrative processes at the Federal University of Ouro Preto, based on the adaptation of an open-source language model. The general objective of the project was to build a vector knowledge base from the institution's official documents and integrate it with a language model capable of answering questions about resolutions, notices, and internal regulations. The methodological procedures involved automated collection of documents published by the university's collegiate bodies sector, extraction and segmentation of their textual content, creation of a semantic search vector database, and supervised fine-tuning of a language model through a low-rank adaptation technique in reduced precision. Results indicate that semantic retrieval over a collection of more than ten thousand text segments produced technically consistent answers when combined with a larger instruction-tuned model, whereas fine-tuning applied to a smaller variant of the model was not, by itself, sufficient to eliminate answers inconsistent with the source documents. Relevant hardware constraints for local deployment of the solution were also identified and overcome through quantization strategies and layer partitioning between video memory and system memory. It is concluded that combining information retrieval with open-source language models constitutes a viable and replicable alternative for automating administrative tasks in public institutions with limited computational resources.

Keywords: *Language models. Information retrieval. Public administration. Artificial intelligence.*

1 INTRODUÇÃO

A administração pública brasileira produz e tramita um volume expressivo de documentos normativos, resoluções, portarias, ofícios e editais, cuja localização, interpretação e síntese consomem parcela considerável do tempo de trabalho de servidores técnico-administrativos. Em universidades federais, esse cenário se intensifica pela quantidade de instâncias colegiadas responsáveis pela publicação de atos normativos, o que dificulta o acesso rápido e preciso a informações por parte de discentes, docentes e servidores. A ausência de mecanismos automatizados de busca e síntese sobre esse acervo documental contribui para atrasos processuais, retrabalho e, em alguns casos, para a aplicação de normas já revogadas.

Modelos de linguagem de grande porte (do inglês large language models), caracterizados pela capacidade de generalizar para novas tarefas a partir de poucos exemplos de instrução (BROWN et al., 2020), têm sido adaptados a domínios específicos por meio de técnicas de ajuste fino, com ganhos relevantes de precisão em tarefas especializadas (JOHNSON; WANG, 2024). Ainda que existam iniciativas de adaptação desses modelos aos domínios jurídico e político (KUMAR; SHARMA, 2024; CUI et al., 2023; TAYLOR; WILSON, 2024), a literatura carece de estudos aplicados especificamente à administração pública universitária, contexto marcado por documentos normativos padronizados e fluxos processuais próprios.

Diante desse cenário, o problema de pesquisa que orienta este trabalho consiste em investigar em que medida a combinação entre um mecanismo de recuperação de informação semântica e um modelo de linguagem de código aberto é capaz de automatizar, com fidelidade aos documentos oficiais, a extração de informações e a resposta a perguntas sobre normas administrativas de uma universidade federal. O objetivo geral do projeto é adaptar um modelo de linguagem de código aberto ao domínio da administração pública da Universidade Federal de Ouro Preto (UFOP), automatizando a extração e a consulta a documentos oficiais por meio de um assistente conversacional. Como objetivos específicos, buscou-se: (i) construir um acervo digital de documentos oficiais da universidade; (ii) estruturar uma base

de conhecimento vetorial para recuperação semântica desses documentos; (iii) realizar o ajuste fino supervisionado de um modelo de linguagem sobre o acervo coletado; e (iv) avaliar e documentar as condições de hardware necessárias para a implantação local da solução, de modo a viabilizar sua replicação em ambientes computacionais de baixo custo.

Justifica-se a relevância do trabalho pela disponibilidade de modelos de linguagem de código aberto sob licenças permissivas, que dispensam custos de licenciamento e permitem replicação por outras instituições públicas, e pelo potencial de tais soluções em reduzir o tempo de tramitação de processos administrativos e padronizar respostas a demandas recorrentes da comunidade acadêmica.

2 REFERENCIAL TEÓRICO

Esta seção apresenta os fundamentos teóricos que sustentam a proposta de adaptação de modelos de linguagem de grande porte ao domínio da administração pública, organizados em três eixos: o ajuste fino de modelos de linguagem para domínios específicos; a recuperação de informação como estratégia de fundamentação de respostas geradas por modelos de linguagem; e a adoção de tecnologias de inteligência artificial em instituições de ensino.

2.1 Ajuste fino de modelos de linguagem para domínios específicos

O ajuste fino (do inglês fine-tuning) consiste em especializar um modelo de linguagem previamente treinado em grandes volumes de texto genérico para tarefas ou domínios específicos, por meio de treinamento adicional sobre um corpus mais restrito e representativo do domínio de interesse. Johnson e Wang (2024) demonstram que essa estratégia produz ganhos de desempenho relevantes em tarefas especializadas sem exigir os volumes de dados necessários ao pré-treinamento original. Entre as técnicas de ajuste fino eficiente, destaca-se a adaptação de baixo posto (LoRA), que insere um pequeno par de matrizes treináveis em cada camada do modelo, mantendo os pesos originais congelados (HU et al., 2021), e sua variante em precisão reduzida (QLoRA), que combina essa técnica à quantização de 4 bits dos pesos

do modelo base, permitindo o ajuste fino de modelos de bilhões de parâmetros em placas de vídeo com memória limitada (DETTMERS et al., 2023).

Exemplos de adaptação de modelos de linguagem a domínios especializados podem ser observados no setor jurídico, com a família de modelos SaulLM (KUMAR; SHARMA, 2024) e com o ChatLaw, modelo jurídico de código aberto integrado a bases de conhecimento externas (CUI et al., 2023), e no domínio político, com estudos sobre o uso de modelos de linguagem na análise de discurso político e democrático (TAYLOR; WILSON, 2024; RODRÍGUEZ; FERNÁNDEZ, 2023). Ainda que esses domínios compartilhem com a administração pública a presença de linguagem formal e estruturada, observa-se lacuna na literatura quanto à aplicação dessas técnicas especificamente a processos administrativos de instituições públicas de ensino superior.

2.2 Recuperação de informação e fundamentação de respostas geradas por modelos de linguagem

Modelos de linguagem, quando utilizados isoladamente, podem produzir respostas plausíveis do ponto de vista linguístico, porém factualmente incorretas ou não fundamentadas em fontes verificáveis, fenômeno conhecido como alucinação. A geração aumentada por recuperação (retrieval-augmented generation) foi proposta por Lewis et al. (2020) como estratégia para ancorar a geração de texto em documentos recuperados de uma base de conhecimento externa no momento da consulta, reduzindo a dependência exclusiva do conhecimento paramétrico do modelo. Zhang, Liu e Wang (2023) propõem uma reformulação desse princípio voltada especificamente à adaptação de domínio, estruturada como um processo de recuperação, adaptação e revisão (adapt-retrieve-revise). Em ambos os casos, a fundamentação das respostas em documentos recuperados favorece a rastreabilidade das respostas geradas até sua fonte documental.

A construção de bases de conhecimento vetoriais a partir de conjuntos de documentos, associada a modelos de geração de texto, tem sido apontada como estratégia eficaz para garantir que respostas de sistemas de inteligência artificial estejam fundamentadas em bases oficiais (GARCÍA; LEE; PATEL, 2024). Martínez e Silva (2025) discutem ainda o desenvolvimento e o ajuste fino de modelos de linguagem voltados à automação de tarefas

manuais, indicando ganhos de eficiência quando esses modelos são combinados a pipelines estruturados de pré-processamento e anotação de dados.

2.3 Inteligência artificial em instituições de ensino: uma interface com a educação

A adoção de tecnologias digitais e de inteligência artificial em instituições de ensino tem sido objeto de investigação crescente, sobretudo quanto aos seus benefícios e desafios de implementação. Lambebo et al. (2023), em revisão sistemática sobre chatbots no ensino superior, identificam aplicações voltadas ao atendimento de dúvidas administrativas e acadêmicas de estudantes, ao lado de desafios relacionados à precisão das respostas e à necessidade de manutenção contínua das bases de conhecimento. De forma convergente, Lopes Junior et al. (2025), em revisão integrativa sobre tecnologias digitais e inteligência artificial na educação em saúde, identificam benefícios como a personalização do ensino e o suporte a práticas profissionais, ao lado de desafios relacionados à desigualdade de acesso, à necessidade de capacitação de profissionais e a questões éticas associadas à privacidade e ao viés algorítmico. Tais achados dialogam com o presente trabalho na medida em que a automação de processos administrativos universitários também depende de investimentos em infraestrutura computacional e de atenção a critérios de transparência e fundamentação das respostas geradas, de modo a preservar a confiabilidade da informação institucional oferecida à comunidade acadêmica.

3 METODOLOGIA

A pesquisa caracteriza-se como um estudo de desenvolvimento tecnológico, de natureza aplicada, estruturado em quatro etapas sequenciais: coleta de dados, construção da base de conhecimento vetorial, ajuste fino do modelo de linguagem e implantação do sistema. O desenvolvimento foi conduzido em três ambientes computacionais complementares: um notebook pessoal (processador AMD Ryzen 7 3750H, 24 gigabytes de memória RAM e placa de vídeo dedicada com 4 gigabytes de memória de vídeo), utilizado nas fases iniciais de prototipagem; uma workstation de laboratório de pesquisa (processador Intel i7-4790K, 24 gigabytes de memória RAM, sem placa de vídeo dedicada de alto desempenho), utilizada nos

testes de implantação local; e a plataforma de computação em nuvem Google Colaboratory, utilizada nas etapas de ajuste fino do modelo. As etapas são descritas nas subseções a seguir.

3.1 Coleta de dados

A coleta de documentos oficiais foi realizada por meio de um script desenvolvido em linguagem Python, que percorreu de forma automatizada o portal público de atos normativos da UFOP (Sistema de Órgãos Colegiados), requisitando sequencialmente as páginas correspondentes a um intervalo de 5.000 números de resolução. Para cada documento, o script verificava a presença do marcador “(REVOGADA)” no corpo da página, descartando automaticamente da coleta os documentos identificados como revogados, de modo a evitar a inclusão de normas sem validade vigente na base de conhecimento. Documentos válidos tiveram seu arquivo em formato PDF localizado e baixado, com nomenclatura padronizada pelo número da resolução para preservar a rastreabilidade cronológica do acervo. Um intervalo de um segundo entre requisições consecutivas foi adotado como medida de uso responsável do servidor do portal. Do total de 5.000 números de resolução verificados nesse intervalo, 4.700 documentos em formato PDF foram efetivamente recuperados e submetidos à conversão para texto puro; após o descarte de arquivos corrompidos ou com falhas de extração, restaram 3.700 documentos de alta integridade, posteriormente segmentados nos blocos de texto indexados na base vetorial descrita na subseção 3.2. Essa etapa contou com apoio de colegas do laboratório de pesquisa na fase de desenvolvimento do script de coleta.

3.2 Construção da base de conhecimento vetorial

O conteúdo textual dos documentos coletados foi extraído por meio de uma estratégia de dupla biblioteca: a extração primária foi realizada com a biblioteca PyMuPDF, recorrendo-se à biblioteca pdfplumber como alternativa nos casos em que a primeira não produzia texto satisfatório, situação típica de documentos com formatação tabular ou de colunas múltiplas. O texto extraído foi submetido a uma etapa de limpeza, que removeu ruídos característicos do sistema de tramitação eletrônica institucional, como marcações de data e hora, endereços eletrônicos, cabeçalhos repetidos e blocos de assinatura digital.

Na sequência, o texto de cada documento foi segmentado em blocos (chunks) de aproximadamente 400 palavras, com sobreposição de 60 palavras entre blocos consecutivos, de modo a preservar o contexto de trechos localizados na fronteira entre dois segmentos. Cada segmento foi convertido em uma representação vetorial (embedding) por meio do modelo multilíngue multilingual-e5-base, especializado em capturar similaridade semântica em textos de diferentes idiomas, incluindo o português. Os vetores resultantes foram indexados em um banco de dados vetorial persistente (ChromaDB), configurado para recuperação por similaridade de cosseno. Ao final dessa etapa, a base de conhecimento contava com 10.314 segmentos de texto indexados, extraídos do conjunto de documentos oficiais coletados.

3.3 Ajuste fino do modelo de linguagem

Antes da definição do modelo de base utilizado no ajuste fino, avaliou-se a viabilidade de duas alternativas de maior porte. A primeira tentativa, com o modelo GPT-OSS 120B, resultou em erro de estouro de memória (Out of Memory) já na etapa de carregamento, uma vez que o modelo exige mais de 200 gigabytes de memória de vídeo para operação, valor incompatível com a infraestrutura computacional disponível ao projeto. Em seguida, testou-se o modelo GPT-OSS 20B, sobre o qual foram conduzidos treinamentos de pré-treinamento contínuo (continuous pre-training) e de ajuste fino supervisionado; entretanto, o modelo resultante apresentou latência elevada de resposta e baixa precisão na geração de texto em língua portuguesa, o que motivou sua descontinuação. A partir dessas avaliações, optou-se pela família de modelos Qwen2.5, que demonstrou equilíbrio mais adequado entre porte do modelo, velocidade de inferência e capacidade de compreensão do português no domínio normativo da UFOP.

Para a etapa de ajuste fino, adotou-se a técnica de adaptação de baixo posto em precisão reduzida (QLoRA) (DETTMERS et al., 2023), que permite especializar um modelo de linguagem por meio do treinamento de um pequeno conjunto de parâmetros adicionais, mantendo os pesos originais do modelo congelados e quantizados em 4 bits. Essa técnica viabiliza o ajuste fino de modelos de bilhões de parâmetros em ambientes com recursos computacionais limitados, como unidades de processamento gráfico disponibilizadas gratuitamente pela plataforma Google Colaboratory.

O conjunto de treinamento foi construído a partir dos segmentos de texto extraídos, formatados no padrão de conversação ChatML, associando a cada trecho de documento uma instrução de extração de informações e uma resposta de referência gerada automaticamente a partir de elementos identificáveis no texto, como número da resolução, data de publicação e artigos normativos, estratégia próxima à geração automatizada de pares de instrução e resposta descrita por Wang et al. (2022). O modelo de base inicialmente adotado foi o Qwen2.5-1.5B-Instruct, ajustado por meio de adaptadores de baixo posto (HU et al., 2021) com rank 16 e fator de escala 32, aplicados às camadas de atenção e de projeção da rede neural, com treinamento conduzido por três épocas, tamanho de lote unitário com acumulação de gradiente equivalente a um lote efetivo de oito amostras, taxa de aprendizado inicial de 2×10^{-4} e escalonamento por cosseno.

3.4 Avaliação e implantação

A avaliação qualitativa preliminar do modelo ajustado na variante de 1,5 bilhão de parâmetros revelou respostas com conteúdo não fundamentado nos documentos recuperados pela base vetorial, fenômeno consistente com o descrito na literatura como alucinação (ZHANG; LIU; WANG, 2023). Em razão desse resultado, optou-se por avaliar, em caráter comparativo, a variante Qwen2.5-7B-Instruct do mesmo modelo, sem ajuste fino adicional, combinada à mesma base de recuperação. Essa etapa de comparação formal entre variantes com e sem ajuste fino permanece em andamento, conforme detalhado na seção de resultados.

Para a implantação local do sistema, testou-se o carregamento do modelo de 7 bilhões de parâmetros quantizado em 4 bits em um notebook equipado com placa de vídeo de 4 gigabytes de memória de vídeo dedicada, configuração representativa de equipamentos de baixo desempenho disponíveis em setores administrativos. Diante de restrições de memória identificadas nesse processo, avaliou-se uma estratégia alternativa de implantação baseada no formato GGUF e na biblioteca llama.cpp, que permite particionar as camadas do modelo entre a memória de vídeo e a memória do sistema, viabilizando a execução do modelo completo mesmo em placas de vídeo com memória insuficiente para comportar a totalidade dos parâmetros quantizados.

4 RESULTADOS E DISCUSSÃO

A execução do script de coleta sobre o intervalo definido de números de resolução (8.137 a 13.137) resultou em um acervo de documentos oficiais da UFOP disponível para processamento, do qual foram extraídos, após as etapas de limpeza e segmentação, 10.314 blocos de texto indexados na base de conhecimento vetorial. Testes exploratórios de recuperação semântica, realizados com perguntas típicas do contexto de iniciação científica institucional, indicaram que a base vetorial foi capaz de recuperar trechos de documentos tematicamente pertinentes às consultas realizadas, com valores de similaridade de cosseno compatíveis com respostas relevantes.

No que se refere ao ajuste fino do modelo de linguagem, o treinamento da variante Qwen2.5-1.5B-Instruct foi concluído com sucesso do ponto de vista técnico, produzindo um adaptador de baixo posto funcional. Entretanto, testes qualitativos indicaram que o modelo resultante, mesmo operando em conjunto com a base de recuperação, produzia respostas parcialmente desalinhadas com o conteúdo dos documentos fornecidos como contexto. Esse resultado é consistente com a literatura que aponta limitações de modelos de menor porte em seguir de forma consistente instruções de fundamentação restrita a um contexto fornecido (ZHANG; LIU; WANG, 2023), sugerindo que a capacidade do modelo base pode influenciar a fidelidade das respostas tanto quanto, ou mais do que, o ajuste fino aplicado especificamente ao domínio.

A substituição do modelo de 1,5 bilhão de parâmetros pela variante de 7 bilhões de parâmetros, sem ajuste fino adicional, mostrou-se qualitativamente mais consistente com os documentos recuperados nos testes realizados até o momento. Esse achado, embora relevante, constitui um resultado preliminar: até a elaboração deste artigo, não havia sido concluído o ajuste fino supervisionado da variante de 7 bilhões de parâmetros, de modo que a comparação sistemática entre modelo de maior porte com e sem ajuste fino — incluindo métricas quantitativas de precisão, revocação e pontuação F1 na extração de entidades, bem como avaliação humana da qualidade de geração — permanece como etapa futura do projeto, não contemplada nos resultados aqui relatados.

Um segundo conjunto de resultados relevantes refere-se às condições de hardware necessárias para a implantação local da solução. A tentativa de carregar o modelo de 7 bilhões de parâmetros quantizado em 4 bits em uma placa de vídeo com 4 gigabytes de memória dedicada resultou em interrupção do processo por esgotamento de memória de vídeo, evidenciando que a configuração mínima efetivamente necessária, estimada entre 5,5 e 6,5 gigabytes, considerando os pesos quantizados, a camada de embeddings em precisão de 16 bits e o espaço reservado para o contexto de execução, excede a capacidade de equipamentos de entrada, comuns em setores administrativos de instituições públicas. Esse resultado é relevante na medida em que reflete uma limitação prática frequentemente omitida em trabalhos que relatam apenas a viabilidade técnica de modelos de linguagem em ambientes de nuvem com grande capacidade computacional.

Um segundo caso de implantação, conduzido em uma workstation de laboratório equipada com processador Intel i7-4790K e sem placa de vídeo dedicada de alto desempenho, evidenciou de forma ainda mais acentuada as limitações de hardware de baixo desempenho para a execução local do modelo. Nesse ambiente, a execução do modelo em precisão de 16 bits inteiramente sobre a unidade central de processamento resultou em tempo de resposta superior a 30 minutos por consulta, mesmo após a aplicação de estratégias de otimização como o processamento paralelo entre os núcleos do processador e a penalização de repetição de tokens durante a geração. Esse resultado reforça, por um caminho distinto e complementar ao caso da placa de vídeo com memória insuficiente, a necessidade de estratégias de quantização mais agressivas para viabilizar a implantação do sistema em equipamentos de baixo desempenho, tanto por limitação de memória de vídeo quanto por limitação de capacidade de processamento da unidade central.

Como resposta a essa limitação, delineou-se uma estratégia de implantação baseada no formato de quantização GGUF, executado por meio da biblioteca llama.cpp, que permite distribuir as camadas do modelo entre a memória de vídeo disponível e a memória principal do sistema. Diferentemente da abordagem baseada exclusivamente em bibliotecas de quantização voltadas a acelerador gráfico, essa estratégia não exige que a totalidade do modelo resida na memória de vídeo, tornando viável a execução do modelo de 7 bilhões de parâmetros mesmo em equipamentos com recursos gráficos limitados, ainda que às custas de

desempenho de geração inferior ao obtido em unidades de processamento gráfico com maior capacidade de memória. A validação empírica dessa estratégia, incluindo a mensuração do tempo de resposta em função do número de camadas alocadas à placa de vídeo, encontra-se em andamento.

5 CONCLUSÃO

Os resultados parciais apresentados neste trabalho indicam que a combinação entre uma base de conhecimento vetorial construída a partir de documentos oficiais e um modelo de linguagem de código aberto constitui estratégia tecnicamente viável para apoiar a automação de processos administrativos em instituições públicas de ensino superior. A construção da base vetorial, com mais de dez mil segmentos de texto indexados a partir do acervo normativo da UFOP, e os testes qualitativos de recuperação realizados demonstram a viabilidade da etapa de recuperação de informação proposta nos objetivos específicos do projeto.

Por outro lado, os resultados relativos ao ajuste fino do modelo de linguagem permanecem parciais. A experiência conduzida com a variante de 1,5 bilhão de parâmetros revelou limitações de fidelidade ao contexto fornecido, ao passo que a variante de 7 bilhões de parâmetros, ainda sem ajuste fino, apresentou resultados qualitativamente superiores nos testes exploratórios realizados. Esse achado motiva a etapa seguinte do projeto, que consiste na condução do ajuste fino supervisionado também sobre a variante de maior porte, de modo a permitir uma comparação sistemática, fundamentada em métricas quantitativas de extração de informação e em avaliação humana da qualidade das respostas geradas, entre as configurações com e sem ajuste fino.

Adicionalmente, a identificação de restrições de memória de vídeo como fator limitante à implantação local do modelo, e o delineamento de uma estratégia de quantização híbrida entre memória gráfica e memória de sistema como resposta a essa limitação, constituem contribuição relevante do trabalho para a replicabilidade da solução em instituições públicas com infraestrutura computacional restrita objetivo alinhado à justificativa original do projeto quanto à adoção de modelos de licença aberta e de baixo custo de implantação.

Como trabalhos futuros, destacam-se: a conclusão do ajuste fino da variante de 7 bilhões de parâmetros; a avaliação quantitativa formal do sistema, por meio de métricas de precisão, revocação e pontuação F1 na extração de entidades normativas, além de avaliação humana da qualidade dos relatórios gerados; a validação da estratégia de implantação híbrida entre memória de vídeo e memória de sistema em equipamentos de diferentes configurações; e o desenvolvimento de um protótipo de chatbot integrado a fluxos de atendimento da comunidade acadêmica, conforme previsto no planejamento original do projeto.

AGRADECIMENTOS

Agradece-se a Guilherme Augusto Anício Drummond do Nascimento pela contribuição decisiva na etapa inicial de coleta de dados, com o auxílio do desenvolvimento do script de raspagem que viabilizou a construção do acervo documental utilizado neste trabalho. Sua colaboração representou uma economia estimada de três meses de trabalho manual e ampliou a perspectiva do autor principal sobre a aplicação da linguagem Python para além de contextos pontuais, incorporando-a como ferramenta de uso cotidiano ao longo do desenvolvimento do projeto.

Agradece-se também a Brendha Alexania Pereira Godinho pelo apoio pessoal oferecido ao longo de todas as etapas do projeto, bem como pela disponibilização de equipamento computacional em momentos pontuais de teste e validação dos scripts desenvolvidos.

REFERÊNCIAS

BROWN, T. B. et al. Language models are few-shot learners. **arXiv preprint arXiv:2005.14165**, 2020.

CUI, J. et al. ChatLaw: open-source legal large language model with integrated external knowledge bases. **arXiv preprint arXiv:2306.16092**, 2023.

DETTMERS, T. et al. LLM.int8(): 8-bit matrix multiplication for transformers at scale. **arXiv preprint arXiv:2208.07339**, 2022.

DETTMERS, T. et al. QLoRA: efficient finetuning of quantized LLMs. **arXiv preprint arXiv:2305.14314**, 2023.

GARCÍA, M.; LEE, S.; PATEL, R. A framework for domain-specific dataset creation and adaptation of LLMs. **Computers**, MDPI, v. 14, n. 5, p. 172, 2024.

HU, E. J. et al. LoRA: low-rank adaptation of large language models. **arXiv preprint arXiv:2106.09685**, 2021.

JOHNSON, L.; WANG, P. Fine-tuning large language models for specialized use cases. **Computers & Electrical Engineering**, Elsevier, v. 102, artigo 1147, 2024.

KUMAR, V.; SHARMA, R. SaulLM-54B & SaulLM-141B: scaling up domain adaptation for the legal sector. **arXiv preprint arXiv:2407.19584**, 2024.

LAMBEBO, K. et al. Chatbots in higher education: a systematic review. **IEEE Access**, 2023.

LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. **arXiv preprint arXiv:2005.11401**, 2020.

LOPES JUNIOR, J. E. G. et al. Tecnologias digitais e inteligência artificial na educação em saúde: transformações do ambiente acadêmico ao contexto hospitalar. **Revista Educação & Ensino - ISSN 2594-4444**, Fortaleza, v. 9, n. 1, 2025. DOI: 10.71136/ree.v9i1.882. Disponível em: <https://periodicos.uniateneu.edu.br/index.php/revista-educacao-e-ensino/article/view/882>. Acesso em: 15 jul. 2026.

MARTÍNEZ, P.; SILVA, F. Development and fine-tuning of LLMs to automate manual tasks. **Journal of Automation and Control Engineering**, v. 8, n. 2, p. 98-112, 2025.

RODRÍGUEZ, L.; FERNÁNDEZ, G. Large language models and political science. **Frontiers in Political Science**, v. 6, artigo 12, 2023.

SMITH, J.; DOE, J. The critical role of fine-tuning in public opinion simulation. **arXiv preprint arXiv:2409.19308**, 2024.

TAYLOR, B.; WILSON, C. Large language models in politics and democracy. **arXiv preprint arXiv:2412.04498**, 2024.

WANG, Y. et al. Self-Instruct: aligning language models with self-generated instructions. **arXiv preprint arXiv:2212.10560**, 2022.

ZHANG, Y.; LIU, X.; WANG, J. Reformulating domain adaptation of LLMs as adapt-retrieve-revise. **arXiv preprint arXiv:2310.03328**, 2023.

Recebido em: dd/mm/aaaa (preenchido pelo editor)

Aprovado em: dd/mm/aaaa (preenchido pelo editor)